


人臉活體檢測金融科技報告

報告目的


台大金融科技中心致力於運用資訊科技產生創新的服務及商業應用，來推動金融科技業的蓬勃發展，近年來人臉辨識系統在現代生活中已無所不在，舉凡行動裝置的解鎖機制、網路銀行用戶認證、門禁管理等，都仰賴此技術。然而，隨著大眾對於資訊安全的意識越來越高，人臉辨識系統的安全性問題也成了設計時的重要考量。為防止有人惡意使用帶有他人肖像的媒介進行攻擊及入侵，人臉活體檢測的技術相應而生。人臉活體檢測是一種用於確認拍攝人臉是否為真實用戶的技術。用戶在登入系統時會使用相機或是筆電、行動電話等裝置的攝影機錄製影片，活體檢測系統將分析影片中的人臉是否為真實用戶。有鑑於此類技術的蓬勃發展，本中心預計透過這篇報告向大眾說明近年此項技術的進展與趨勢，並闡述真實場景的潛在應用與發展可能，提供給相關從業人員做為參考。



圖一：2010 至 2021 年人臉活體檢測相關題目的論文發表數量，可以看到呈現一個指數型上升的趨勢。（圖片來源：Deep Learning for Face Anti-Spoofing: A Survey[6]）

系統流程

在實務上，人臉活體檢測模型通常會搭配人臉辨識系統做使用，具體流程如下：首先，透過攝影裝置獲取影像或影片後，依序或是平行輸入人臉活體檢測網路及人臉辨識系統，前者的任務是判斷人臉真偽，後者的任務則是搭配資料庫的搜索，辨別人臉是否為已註冊的正確用戶。透過以上兩項技術的檢測，期望能有效過濾偽造攻擊，並準確讓真實用戶順利通過。




圖二：人臉活體檢測系統與人臉辨識系統的流程圖（圖片來源：Deep Learning for Face Anti-Spoofing: A Survey[6]）

主要攻擊型態介紹

對於人臉活體檢測的任務來說，能有效的辨認真實及攻擊影像是首要關鍵。而攻擊型態又可分為平面 (2D) 或立體 (3D)、局部或整臉，目的亦可分為偽裝成他人或隱藏攻擊者自身特徵等。以下列舉幾種學術界公開發表的資料集中有涵蓋到的攻擊型態：

1. Print(2D)：使用列印有他人照片的紙張作為攻擊媒介。
2. Replay(2D)：使用平板、筆記型電腦等電子設備顯示他人照片或影片。
3. Mask(3D)：仿照他人面孔製作像是紙張、樹脂等面具。
4. Mannequin：使用人體模特兒的頭部做偽裝。
5. Glasses：穿戴一般或配有眼部裝飾的眼鏡。
6. Makeup：利用化妝技巧掩蓋或加入臉部特徵。
7. Tattoo：利用刺青技巧掩蓋或加入臉部特徵。




圖三：常見攻擊型態及其範例圖片（圖片來源：Deep Learning for Face Anti-Spoofing: A Survey[6]）

以上包含了目前多數資料集所涵蓋的攻擊型態，其中 **print** 和 **replay** 這兩種攻擊型態較早出現，也是較多資料集有涵蓋到的類型，然近期研究也有漸漸往辨識他種攻擊（如面具類或局部偽裝）發展的趨勢。而實務上會面臨的攻擊則可能更五花八門，且目前尚未知的新型態攻擊永遠層出不窮，這也將是人臉活體檢測任務需要時刻關注並與時俱進的一大課題。

認證對象

我們將逐一介紹人臉活體檢測技術的各種做法，並著重在近年來蓬勃發展的深度學習相關方法做更深入地探討。深度學習是過往傳統機器學習的分支，是一種以人工神經網路為基礎架構，去學習資料特徵的演法。針對人臉活體檢測相關的深度學習技術可以參考下圖的各支，由圖中可以看到，首先在拍攝裝置上可分為單純 RGB 相機或是附有額外感測器的攝影機，其中大多數研究都是以使用單純 RGB 相機為主，原因是雖然帶有額外感測器的攝影機可獲取除了 RGB 影像以外的資訊，例如：深度、近紅外光(Near Infrared, NIR) 等，在模型建構上會有較多資訊可做為判斷依據，然而這樣的設計本身在實務上會有其限制，原因是多數拍攝裝備（例如手機的前置鏡頭）並不會帶有這樣額外的功能，因此本篇也將著重在 RGB 相機裝置的前提，不會就帶有感測器假設下的相關技術做深入探討。針對單純 RGB 相機裝置的情境又可分為以下三種做法，首先是結合傳統特徵提取方式及深度學習技術的方法，接著發展到完全使用深度學習模型做端到端的訓練，最後針對未知領域和未知攻擊型態這兩項挑戰，又發展出更進階的深度學習訓練技巧來解決此類問題，後續在「技術發展說明及應用討論」此章節會針對這三大發展方向有更進一步的介紹。



圖四：人臉活體檢測任務相關的深度學習技術發展方向與分支。（圖片來源：Deep Learning for Face Anti-Spoofing: A Survey[6]）

認證指標

人臉活體檢測的最終目標就是要辨認當前影像為真實用戶抑或是攻擊者。針對這種二分類問題，模型最終會針對每張輸入影像輸出一個預測機率值，也就是判斷此影像為真實用戶的機率。透過事先設定一個檢測門檻值，我們即可與輸出的機率比較大小並將影像歸類（可理解為超過一定信心我們便讓它通過檢測），最後再將分類結果與已知的實際類別做比對，即可得知檢測表現的好壞。而比對後具體的分類結果又可分為以下四種情境，前兩者代表系統做出正確的

判斷，後兩者則代表錯誤的檢測：

1. 真陽性(True positive, TP)：正確地讓真實用戶通過檢測。
2. 真陰性(True negative, TN)：正確地拒絕攻擊者的入侵。
3. 偽陽性(False positive, FP)：錯誤地讓攻擊者通過並入侵。
4. 偽陰性(False negative, FN)：錯誤地拒絕真實用戶的進入。

根據以上的分類結果，設計了以下三種基礎指標來檢測表現：

1. 錯誤拒絕率(False Rejection Rate, FRR)：所有真實用戶中，誤將其辨認為攻擊者的機率有多少，此項指標關乎真實用戶的使用者體驗。具體計算方式如下：

$$\text{下：} \frac{\text{False Negative}}{\text{True Positive} + \text{False Negative}}。$$

2. 錯誤接受率(False Acceptance Rate, FAR)：所有攻擊者中，誤判斷為真實用戶並讓其入侵的機率有多少，此項指標關乎系統的安全性問題。具體計算方式如下：

$$\text{如下：} \frac{\text{False Positive}}{\text{True Negative} + \text{False Positive}}。$$

3. 平均錯誤率(Half Total Error Rate, HTER)：錯誤拒絕率和錯誤接受率的平均。

$$\text{具體計算方式如下：} \frac{\text{False Rejection Rate} + \text{False Acceptance Rate}}{2}。$$


以上指標數字都是越低越好，可以看到人臉活體檢測技術有兩種辨認錯誤的情境，這兩項錯誤情境存在著某種互斥關係一較嚴苛的門檻值可能造成更多真實用戶無法順利通過檢測，但會降低攻擊者入侵機會；反之較寬鬆的標準則會降低系統安全性。因此，就實務應用場域的不同，我們需要去權衡哪一項才是我們要著重優化的目標。舉例來說，若是在網路銀行登入系統這種攸關個人財務安全的情境，甚至是更高安全層級的軍事或公安領域等需高度控管的場域中，錯誤地讓攻擊者入侵系統(false positive)帶來的後果往往比誤把真實用戶當成攻擊者(false negative)更為嚴重，此時降低錯誤接受率(false acceptance rate)便是我們要積極追求的部分；然而像是大樓門禁系統若權衡門禁控管和系統方便性後，或許會考慮以使用者體驗為主要訴求，而相對能容忍較高的錯誤接受率(false acceptance rate)，試圖優化並降低錯誤拒絕率(false rejection rate)。

當然，為求兩者之間的平衡，同時盡量減低不同門檻值設定的影響，我們也有了以下兩個較普遍性的指標來綜合考量表現：

1. 等錯誤率(Equal Error Rate, EER)：調整門檻值，找到錯誤接受率和錯誤拒絕率相等時的數值，此數值越低越好。
2. Area Under the Curve(AUC)：ROC 曲線下的面積，較大的面積代表綜合考量不同門檻值後，模型總體來說有較低的錯誤接受/拒絕率。

以上兩種指標和前述錯誤接受/拒絕率的關係可以用圖五來呈現。首先橫軸是錯誤接受率，縱軸是 (1 - 錯誤拒絕率)，等同於正確接受率，代表所有真實用戶中，正確被檢測通過的比例。當錯誤接受率越高時，按常理正確接受率也會提

高，代表檢測條件較為寬鬆的情況，圖中圓弧狀曲線便代表兩者的正向關係，這條曲線也被稱為 ROC(receiver operating characteristic curve) 曲線。而等錯誤率(EER)剛好會是曲線上的一點，在這一點上錯誤拒絕率(FRR)及錯誤接受率(FAR)數值相等，且總和為最小，可視為模型會有最均衡效能的情況。另外，計算曲線下面積也可以得到另一項評量指標 Area Under the Curve(AUC)，原則上我們希望在較小的錯誤接受率(FAR)下，有較高的正確接受率(1-FRR)，因此面積是越大越好。



圖五：FAR, FRR, AUC 和 EER 之間的關係圖。

除了上述學術界共同訂定用來衡量模型預測能力(effectiveness)的指標外，實務應用上也可能會追求更好的模型效率(efficiency)，期望能在維持一定的表現下，有更輕量（降低硬體資源如 GPU, memory 等需求）並節省能源消耗的解決方案來符合企業永續發展趨勢；針對反應時間(inference time)也希望能盡可能縮短以提升使用者體驗，並期望模型能良好適應並符合實際應用場域下的資料，並有效地做出更動與改進，這些指標也將是學術發表過渡到實際應用時會需要格外重視與關注的面向。

技術發展說明及應用討論

以下將遵循前述所提到的認證對象三大範疇，逐一說明近年來深度學習相關技術在人臉活體檢測任務上的發展趨勢，並討論其表現及實務應用可能。

1. 人工特徵提取方法搭配深度學習 (Handcraft + Deep Learning Method)

在較早期，人臉活體檢測是透過人工設計特徵提取方式來偵測攻擊。這些特徵提取方式可分為兩個面向，首先第一種是偵測人體生理活動，例如眼睛移動或嘴巴開合等面部表情變化，或是心跳帶來的血液流動在皮膚形成的週期性反射(remote Photoplethysmography, rPPG)等來判別是否為假人臉。這樣的偵測方式在輸入的部分會需要擷取一段較長的影片或連續多張影像才可做

判別，在應用上會較為不便，且單純使用這樣的方法僅能辨別出靜態影像 (print) 或面具類 (mask) 的攻擊，影片類 (replay) 的攻擊則可以輕易模擬人體的生理活動並騙過系統；另外一種特徵抓取方式則是使用傳統影像處理技術，例如 LBP (Local Binary Pattern, LBP)、HOG (Histogram of oriented gradient) 等來抽取圖片特徵並作為判斷依據。在機器學習及深度學習開始發展至這個領域的初期，人們發現傳統 CNN 架構在其他電腦視覺任務上可以輕易的抓取足夠有代表性的特徵來作為分類依據，然而人臉活體檢測任務本身有其獨特性——人臉主體特徵差異性較大，反而是真實與攻擊兩類別之間的特徵差異較小。面對這樣的特性，上述傳統影像處理方法能夠萃取出圖片較細節的資訊（例如圖片紋理、顏色），進而輔助深度學習模型去找出更廣義的語意資訊，從而進行判斷。不過這個方向潛在的缺點是需要專家對此領域有一定的了解後，再去設計合適的特徵提取方法，同時這樣的設計過程是無法被訓練並改進的，因此在現今資訊和資料量爆炸性成長的時空背景下，這類做法也就較沒有其必要性，研究方向也漸趨轉往利用大量訓練資料的方向發展。

2. 傳統深度學習方法 (Traditional deep learning method)

隨著深度學習技術的蓬勃發展，人臉活體檢測相關的大型資料集相繼釋出，使得這方面的研究也有如雨後春筍般大量出現。要將深度學習技術應用在人臉活體檢測任務上，最直接的做法便是訓練一個端對端的神經網路模型，並利用交叉熵 (cross-entropy loss) 做為網路的優化目標，這裡可以簡單想成是最小化預測類別及正確類別的差距。最初的嘗試大多採用從零開始訓練模型的方式，直到後來大型預訓練模型 VGG16, ResNet18 等釋出，才使得訓練過程變成以這些模型為基底，針對當前任務再去做微調 (fine-tune)；而後來 transformer 模型的興起又讓訓練的基底被抽換成 vision transformer 系列的模型，在這過程中表現又有了更進一步的提升。不過值得一提的是，由於 transformer 系列的模型架構較為龐大和複雜，在實際應用上可能會有其不便，因此也有相關論文在探討如何抽換成較輕量的模型基底（如 MobileNetV2, MobileViT），讓人臉活體檢測任務可以在行動裝置上良好的運行。

由於上述端到端的訓練方式會讓模型著重在整體的語意資訊，缺乏對圖片局部特徵描述，因此除了上述方法外，也發展出像素層級 (pixel-level) 的訓練方法，搭配空間或時間上的資訊作為輔助。以空間維度舉例來說，Learning deep models for face anti-spoofing: Binary or auxiliary supervision [1] 和 Searching central difference convolutional networks for face anti-spoofing [2] 兩篇論文便使用了「深度」的資訊，基於我們事先對 print 和 replay 兩個較常見的攻擊型態的了解，可以假設承載影像的媒介為平面物體（如紙張、平板等），因此在訓練過程中就可以讓模型學習輸出目前影像的深度，並試圖讓模型學到真實用戶影像會因人臉輪廓而有不同深度，攻擊影像的深度則全為零。當然這樣的前提假設有其缺失的地方，例如面具類 (mask) 的攻擊可能就

效果不彰，也沒辦法確保能泛用到未來實務可能出現的新型態攻擊上。整體來說，像素層級的訓練方式對輸入影像的品質較為敏感，在實務上可能會較容易受到設備畫質好壞影響。

3. 泛化深度學習方法(Generalized deep learning method)

隨著研究日益增多，人們發現傳統的深度學習方法在兩種情境下表現較差，一個是面對未知領域，另一個則是面對未知攻擊。於是，如何有效地改動模型訓練目標及架構，使得原有的做法可以泛化到未知領域及未知攻擊上，進而縮小學術與實務應用差距，便是此方向研究人員亟待解決的議題。

以下我們也將逐一說明這兩項主題的研究近況與發展：

(1) 泛化到未知領域(Generalize to unseen domain)

這邊我們首先要定義「領域」。所謂「領域」在學術研究上來說代表的是不同的資料集，由於資料集通常是不同的研究團隊所提出，而產出的影像之間會有一些整體環境上的差異，例如拍攝背景、光線和裝置（如：相機、手機攝影機等），另外也會因為採集樣本時受試者的不同，而有諸如種族、性別和年齡導致的人臉特徵差異。對於模型來說，若單單在同樣一個資料集上做訓練和測試，會使得我們的模型過度擬合(overfitting)在單一場景，衡量指標表現時也會考慮得不夠周全。

為了讓我們的模型在面臨未知領域的衝擊時有更好的表現，針對此一問題有了以下兩個分支，分別為領域適應(domain adaptation)和領域泛化(domain generalization)兩個研究面向。以下將針對兩者的主要概念和作法進行闡述及討論：

- 領域適應(Domain adaptation)

首先領域適應將問題定義為如何讓原先訓練在特定領域的模型，可以透過取得一些新領域的資訊來做相應調整，而後在新領域有良好的表現，縮短和原領域之間的差距。主流的做法多半是透過對抗式學習(adversarial learning)，使得模型針對不同領域的真實或攻擊圖像，分別生成相似的特徵，也就是讓特徵中不帶有特定領域的資訊，僅保留真實及攻擊圖像的區別。值得一提的是，這裡所取得的新領域資訊多半為「未標註」的資訊，也就是我們實際上並不知道新領域的影像為哪個類別，但能從中提前獲得新領域會有的整體特徵如環境因子等。這樣的設定適用於當同一份模型需要廣泛應用到不同地區或公司的系統時，我們可以透過事先蒐集新地區或公司的資料，來對原有模型進行調整；不過相對的，這樣的技術就沒有辦法在無法取得新領域資訊的情況下使用，而像是新用戶的拍攝裝置或環境條件是我們無法事先得知的，在這部分的表現就會有其侷限性。長遠來說，我們還是期望能有一個更普遍、適用於各種情況的模型，讓我們在無法得知未來可能出現的領域下，也能有良好的表現。因此，領域泛化的研究方向也就應運而生。

- **領域泛化(Domain Generalization)**

要訓練一個具有高度泛化能力的模型，最直觀的想法便是讓所有領域的真實/攻擊特徵都映射在同樣的一個空間中。在這之中，會有一個邊界來分割真實與攻擊兩個類別。要做到讓同樣領域都映射在同個空間中，必須試圖讓模型學習把不同領域的真實圖像都聚集在一起，而攻擊圖像則各自成群並與真實圖像越遠越好，其中 **Single-side domain generalization for face anti-spoofing** [3] 這篇論文便是此類做法的代表作品，也達到了很好的表現。另外，由於一張圖片的特徵是由許多資訊所組成，我們希望僅保留類別相關特徵（如 **print** 攻擊中的紙張材質、**replay** 攻擊裝置的螢幕反射和 **funny glasses** 的眼部裝飾區域），不受其他多餘特徵（如人臉五官特徵、相機解析度、圖片噪音等）影響，因此像 **Shuffled Style Assembly for Face Anti-Spoofing** [4] 這篇論文的作法便是分別訓練兩個模型來抓取人臉特徵和類別特徵，並讓前者在各領域都是相似的，後者則作為主要判斷依據。領域泛化是我們想要達到的終極目標，但在實務上如何兼顧或權衡辨別能力及泛化能力，依舊是需要審慎思考的問題。

(2) 泛化到未知攻擊(Generalize to unknown attack type)

除了新領域適應及泛化的問題外，對於新型態攻擊全然未知也是人臉活體檢測的一大難題。若沒有良好泛化及辨認新型態攻擊的能力，往後對於系統的安全性會有很大的疑慮。因此針對此一問題，在學術上有兩個主要的方向，分別是零樣本或少樣本學習，以及異常檢測。以下將針對這兩項做更深入的說明：

- **零樣本或少樣本學習(Zero/few-shot learning)**

一般深度學習模型仰賴大量的資料做訓練，然而對於新型態的攻擊影像來說，要獲取足夠的資料是十分困難的。因此研究便發展出能夠在擁有少量樣本或甚至無任何樣本的情況下，便正確地偵測新型攻擊的技術。要能辨認新型態的攻擊，必須善用已知攻擊的資訊，找出其中潛在的共同特徵，而不會誤將其歸類為真實用戶。實作上像是 **Deep tree learning for zero-shot face anti-spoofing**[5] 這篇論文利用了 **tree-based** 的模型，一步步根據分支將圖像分類。然而可以想見的是，有些較新型的攻擊相較於常見的 **print** 和 **replay**，可能反而和真實影像更為相似，例如純粹帶上一個眼鏡僅在局部有與真實圖像不同的地方，並不會有整體材質反射等的不同，因此要辨別這些高度仿真(**high fidelity**)的攻擊會是主要難題。儘管如此，零樣本或少樣本學習還是存在諸多應用機會，若能透過少量新型攻擊資料，在線(**online training**)即時地訓練及更新模型，能讓安全性層級再提高，應付源源不斷的未知攻擊。

- 異常檢測(Anomaly Detection)

另一個研究方向則把偵測新型態攻擊定位為異常檢測的任務。假設所有真實類別的資料特徵相似，而攻擊類別的資料因其攻擊手法、媒介不同有較大的差異，那麼我們便可將那些落在真實資料範圍或分布外的影像視為非真實用戶，從而挑出我們認為不合格的影像。換句話說，這個任務變成在檢測一個樣本「是否為真實用戶」，而非此樣本「是真實用戶還是攻擊者」。儘管這樣的假設符合直覺，此方法在模型表現上不一定會比原先二分類的做法好，也會較受資料本身組成的影響，應用到實務場域較有可能會跟學術表現有落差。

實務應用及未來挑戰

隨著人臉辨識技術快速普及到各應用場域，諸如門禁系統、網路銀行身分認證等，人臉活體檢測技術如何即時跟進，保障其安全性問題是一大挑戰。而從最初目標訂定需要權衡安全控管程度和使用者體驗，到後續訓練資料的蒐集，也需要在不侵犯用戶肖像權的情況下，盡可能全方面匯集有用資訊，並且最重要的是如何因應瞬息萬變且源源不絕的新攻擊型態，立即做出相應調整，將會是此類資訊安全防禦任務中關鍵的一環。透過上述的介紹可以看到目前學術上各技術方向皆有其想要解決的問題，同時模型的設計也各有優缺，要將技術落實到實際場域，除了要審慎評估各情境需求外，也有賴產業界與學術界多方溝通並努力落實，未來尚有諸多挑戰和突破空間有待各界人士共同努力邁進。

結論

本報告詳細闡述了人臉活體檢測技術的宗旨，並介紹學術上所定義的攻擊類別及衡量指標，更進一步闡述各技術方向的發展趨勢與演進，並在介紹其做法的過程中討論優缺利弊，以及未來在實際應用時所需考慮的問題。期望透過本報告，能讓有意導入相關技術的從業人員，能對人臉活體檢測在學術上的發展有更深入的了解，並促使未來更多的產學合作機會，讓學用接軌，發揮科技在產業界上更大的效益，共同創造雙贏的局面。

參考來源

- [1] Y. Liu, A. Jourabloo, and X. Liu, "Learning deep models for face anti-spoofing: Binary or auxiliary supervision," in CVPR, 2018.
- [2] Z. Yu, C. Zhao, Z. Wang, Y. Qin, Z. Su, X. Li, F. Zhou, and G. Zhao, "Searching central difference convolutional networks for face anti-spoofing," in CVPR, 2020.
- [3] Y. Jia, J. Zhang, S. Shan, and X. Chen, "Single-side domain generalization for face anti-spoofing," in CVPR, 2020.
- [4] Z. Wang, Z. Wang, Z. Yu, W. Deng, J. Li, T. Gao, and Z. Wang, "Domain

Generalization via Shuffled Style Assembly for Face Anti-Spoofing” in CVPR, 2022.

[5] Y. Liu, J. Stehouwer, A. Jourabloo, and X. Liu, “Deep tree learning for zero-shot face anti-spoofing,” in CVPR, 2019.

[6] Z. Yu, Y. Qin, X. Li, C. Zhao, Z. Lei, and G. Zhao, “Deep Learning for Face Anti-Spoofing: A Survey, ” in IEEE, 2022.